

音樂發行年代與市場分類

凍結特徵分類器、預訓練模型微調，以及本機音訊語言模型的比較

先看較佳表現： 凍結 **MERT** 特徵分類器

兩項任務皆以 30 秒音樂片段預測單一類別。凍結方案的官方驗證表現優於本次微調；以下先呈現凍結方案，再分析微調與音訊語言模型的結果及限制。

學號：待補

凍結 A 發行年代 / Top-1

40.2%

Top-3 83.3% | 132 筆驗證資料

凍結 B 發行市場 / Top-1

41.2%

Top-3 75.5% | 102 筆驗證資料

公開程式碼與重現說明：<https://github.com/jimmynycu/music-era-market-classification>

課程要求之公開雲端資料夾：待補；GitHub 程式碼網址不同課程要求的公開雲端資料夾。

資料集與評估規則

課程資料共 2,292 筆；官方分割依作業說明採歌手互斥。所有 SHA-256 與音訊格式檢查通過。

資料集	任務範圍	訓練	驗證	測試
dataset_A	美國音樂，1960s–2010s	1026	132	132
dataset_B	1980s 音樂，六個發行市場	798	102	102

音訊與類別

每筆皆為 30 秒、單聲道、24 kHz、PCM 16-bit WAV。A 每類訓練 171 筆、驗證 22 筆；B 每類訓練 133 筆、驗證 17 筆。未加入額外標註音訊。

指標定義

Top-1 檢查第一順位是否正確；Top-3 檢查正確答案是否位於三個不同類別的候選清單。混淆矩陣數字均為筆數，列為真實類別、欄為預測類別。

市場標籤的意義

B 的 US、UK、Brazil、Spain、Germany、Italy 表示發行市場，不直接等於歌手國籍、演唱語言或音樂文化。

訓練、選擇與報告分開

凍結方案：只在訓練集做三折交叉驗證。

微調方案：只在訓練集內切出 20% 選擇訓練輪數，再以全部訓練資料重訓。

官方驗證僅供結果報告；微調前已看過凍結方案的驗證結果，因此不能稱為完全未見的確證性測試。測試標籤不可見。

凍結模型：完整片段特徵與訓練內選模

MERT-v1-95M 保持預訓練權重不變；兩個任務各自訓練分類器。模型與公共程式來源見第 10 頁。

01 音訊分段

保留完整 30 秒，切成六段不重疊的 5 秒窗；各窗去均值，除以 $\sqrt{\text{變異數} + 1e-7}$ 。

02 MERT 表示

取 13 層隱藏表示，每層 768 維；跨六段所有影格計算平均與母體標準差，每層 1,536 維。

03 聲學基準

244 維：64 log-mel、20 MFCC、20 差分、12 chroma 與六項描述子的時間平均 / 標準差。

04 分類與選擇

StandardScaler 僅用當折訓練資料擬合，再逐筆 L2 正規化。三折分層交叉驗證，種子 2026。


任務	訓練 CV 選定方案	CV Top-1	CV Top-3
發行年代	分層 MERT + 聲學；Ridge $\alpha=1$	41.7%	79.1%
發行市場	MERT 第 5-8 層平均；Ridge $\alpha=1$	37.3%	73.7%

固定 40 組候選：五種特徵配方 $\times$ [Ridge $\alpha = 0.01 / 0.1 / 1 / 10$; RBF SVC $C = 0.1 / 1 / 10 / 100$, $\text{gamma}=\text{scale}$]。依 Top-1 + 0.5 $\times$ Top-3 最大者選擇，再以 Top-1、固定順序破同分。A 拼接第 1-4 / 5-8 / 9-12 層平均及聲學統計，共 4,852 維；B 為 1,536 維。

聲學設定：STFT 2,048 點、hop 512；描述子為頻譜重心、頻寬、rolloff、flatness、RMS、過零率。無資料增強。

凍結方案結果：發行年代

完整官方驗證集，共 132 筆。矩陣為計數；分類器與特徵由訓練集內 CV 決定。



Top-1

40.2%

53 筆正確

Top-3

83.3%

共 132 筆


多數錯誤落在相鄰年代
47/79 (59.5%) 的 Top-1 錯誤相差 10 年。相差 1-5 個年代的錯誤數依序為 47、15、7、7、3。

類別與混淆
召回率最高 1960s : 17/22 ; 最低 2000s : 4/22。雙向混淆前三名 : 2000s / 2010s : 15 ; 1960s / 1970s : 10 ; 1980s / 1990s : 10。

表示有用，不等於因果解釋
音色、節奏、錄音技術可能帶有年代線索，但目前未做控制實驗，不能由混淆矩陣斷言模型使用了哪一項線索。

凍結方案結果：發行市場

完整官方驗證集，共 102 筆。矩陣為計數；分類器與特徵由訓練集內 CV 決定。



Top-1

41.2%

42 筆正確

Top-3

75.5%

共 102 筆

最高與最低召回率

Brazil : 12/17 (70.6%) ; Spain : 4/17 (23.5%) 。

混淆分散於多個市場

US / UK 有 10 筆雙向混淆，占 60 筆錯誤的 16.7%，並非多數。前三名：US / UK : 10 ; UK / Spain : 7 ; US / Italy : 7。

解讀範圍

發行市場本來就可能共享語言、曲風及製作方式。這些是可能的解釋，尚未以額外標註或消融實驗驗證。

部分微調：實際更新預訓練編碼器

每個任務各自訓練；解凍第 8-11 個 transformer 區塊（索引從 0 起），共 28,351,488 個預訓練參數。

模型與聲音

其餘編碼器固定。最後一層影格平均與 $\text{sqrt}(\text{母體變異數} + 1\text{e-}5)$ 拼成 1,536 維；分類頭為 LayerNorm → Dropout(0.1) → Linear(6)。每輪每首歌隨機裁切 5 秒；推論平均完整六段 logits。

最佳化

FP32、交叉熵、AdamW。主幹 LR $1\text{e-}5$ / 分類頭 LR $1\text{e-}3$ 、weight decay 0.01、梯度範數上限 1；microbatch 4，累積至有效 batch 16。

僅用訓練資料選輪數

種子 2026，分層保留 20% 作內部驗證。在第 1-6 輪最大化 Top-1 + $0.5 \times \text{Top-3}$ ，再按 Top-1、較早輪數破同分。選定後重載原始預訓練權重與全新分類頭，用全部訓練資料重訓。

權重更新的直接證據

兩階段皆量得四個區塊的有限非零梯度；四區塊權重確實改變，凍結參數 SHA-256 前後一致。儲存後重新載入的參數完全相同。

任務	輪數	內部擬合 / 保留	保留 Top-1 / 3	區塊 8 / 9 / 10 / 11 權重 $\Delta L2$
發行年代	6	820 / 206	39.8% / 78.2%	0.865 / 0.777 / 0.709 / 0.678
發行市場	3	638 / 160	26.9% / 60.6%	0.431 / 0.375 / 0.338 / 0.318


驗證曝光揭露：微調方案是在看過凍結方案驗證分數後制定；配方固定後才執行，僅以內部訓練保留集選輪數。官方驗證是描述性比較，不能視為完全未見的確證性測試。

微調結果：未超越凍結分類器

完整官方驗證；兩個任務分別訓練 6 輪與 3 輪。先呈現凍結方案，不代表依驗證結果重新選擇提交模型。

發行年代


Top-1 39.4% | Top-3 79.5% | n=132



相鄰年代錯誤 44/80 (55.0%) ；2000s 召回 0/22 ，僅 1/132 筆預測為 2000s。

發行市場

Top-1 26.5% | Top-3 53.9% | n=102



Brazil、Spain、Germany 完全未被預測為 Top-1，三類召回率皆為零。結果顯示明顯類別集中，不能僅看整體分數。

微調與凍結方案同時改變了池化方式、分類頭，且 A 的凍結方案使用額外聲學特徵，因此此比較無法單獨識別「解凍權重」的因果效果。


音訊語言模型：完整驗證與固定提示詞

Qwen2.5-Omni-3B Thinker；Q4_K_M 語言模型 + Q8_0 音訊投影器；llama.cpp b11049 / Vulkan，僅本機運算。

輸入完整 30 秒 WAV；內部轉為 16 kHz，補 30 秒靜音，以兩個 3,000-frame 區塊產生 1,500 audio tokens。這是實驗性相容路徑，尚未證明等同原始 Transformers。
固定一種提示：聽完整片段，參考可聽見的樂器、節奏、聲線與錄音製作，依可能性排列六類；B 明示市場不等於國籍或語言。未給範例、未用驗證回饋調整。


單一預先制定提示可降低本機成本及解析歧義。[完整原文與標籤映射見 alm_eval.py](#)。
GBNF 限制為六代碼的 720 種排列，嚴格檢查六個代碼各一次，取前三名；6-1 分僅為順序，不是機率。temperature=0、seed=42。無效答案以同輸入重試一次，再失敗用固定排序並標記；伺服器故障則停止。全數 234 筆均有效，無替代排序。

發行年代：Top-1 21.2% / Top-3 62.9% (132 筆)



未預測：1990s、2000s、2010s；最常選 1960s (74/132)。

發行市場：Top-1 31.4% / Top-3 61.8% (102 筆)



未預測：Germany；最常選 US (84/102)。

整體比較、可重現性與限制

以下為官方驗證上的描述性結果；均衡六分類的隨機 Top-1 / Top-3 期望值為 16.7% / 50.0%。

方法	A Top-1	A Top-3	B Top-1	B Top-3
純聲學基準	31.8%	72.0%	22.5%	63.7%
僅 MERT 凍結特徵	41.7%	79.5%	41.2%	75.5%
凍結方案（訓練 CV 選定）	40.2%	83.3%	41.2%	75.5%
部分微調 MERT	39.4%	79.5%	26.5%	53.9%
音訊語言模型	21.2%	62.9%	31.4%	61.8%

本機與重現

i7-4790K、16 GB RAM、GTX 1060 6 GB。微調使用 FP32 累積梯度；凍結特徵以 FP64 池化，分類器使用 1 個 BLAS 執行緒。重新從 WAV 推論，234 筆微調測試排名完全一致（132 A + 102 B）；凍結方案亦通過完整重現。

預測檔分開保留

微調：finetune_predictions.json；凍結：predictions.json。報告排序沒有改變既有提交方法或預測。每筆含三個不同合法標籤；測試標籤隱藏，無法報測試準確率。

比較的限制

A 的凍結選定方案以 Top-3 換取部分 Top-1；並非每個指標都最佳。微調前已看過凍結驗證結果；兩種方案也不同時控制分類頭、池化及聲學特徵，不能宣稱單一因素造成差異。

未知與未驗證因素

歌手資料匿名，訓練內分割無法再按歌手分組；預訓練語料是否包含這些歌曲未知。ALM 類別集中可能與提示順序、量化或實作有關，但尚未隔離原因；不能推論為原始 Qwen 的一般能力。

參考文獻與公開實作來源

以下項目均可點擊；程式、版本、原始輸出、模型檢查與完整提示詞保留於公開儲存庫。

[1] MERT：Li 等，ICLR 2024，音樂自監督表示學習論文。

[2] MERT-v1-95M 權重與程式；固定 revision 12af15fef9d0...；授權 CC BY-NC 4.0，完整版本見連結。

[3] librosa：聲學特徵與音訊分析實作。

[4] scikit-learn：標準化、分類器與交叉驗證；Pedregosa 等，JMLR 2011。

[5] Qwen2.5-Omni：模型論文與原始設計。

[6] Qwen2.5-Omni-3B GGUF；固定 revision 75f1b73b657a...；完整版本見連結。

[7] llama.cpp：b11049 / efa28e950，本機量化音訊推論。

[8] llama.cpp 音訊相容性與實驗性品質限制說明。

[9] PyTorch：編碼器載入、梯度訓練及推論。

[10] Hugging Face Transformers：預訓練模型介面。

[11] NumPy 與 SciPy：數值運算；各套件版本見 requirements.txt。

[12] SciPy 公開實作。

[13] SoundFile：WAV 解碼與輸出。

[14] joblib：凍結分類器與標準化參數儲存。

[15] Matplotlib：結果圖表與混淆矩陣。

[16] 課程作業一、Dataset A / B 清單與資料說明。